

Etude de cas 1 : reconnaissance et traitement de données d'actes d'Etat civil antérieur à 1950

Proposé par Gregory Verdugo, professeur de sciences économiques à CY Cergy Paris Université

Email : gregory.verdugo@cyu.fr

Motivation

Les actes d'états civil, qui comprennent notamment les actes de naissance, mariage et décès, contiennent de riches informations sur les caractéristiques des populations entre villes et régions et leur évolution au cours du temps. Les **actes de mariage** en particulier contiennent des informations sur l'âge, la profession et le lieu de naissance des mariés et de leurs parents respectifs. En sciences sociales, ces informations sont précieuses pour étudier comment les couples se forment, en particulier pour mesurer *l'endogamie sociale* c'est-à-dire la tendance des mariés à appartenir au même milieu social et à avoir un âge proche. L'information sur la profession des parents et des enfants à l'âge du mariage peut également être mobilisée pour mesurer le niveau de *mobilité intergénérationnelle*, c'est-à-dire la tendance des enfants à atteindre le même niveau socio-économique de leur parent.

La loi du 15 juillet 2008 sur les archives facilite l'accès aux documents de plus de 75 ans. La plupart des actes de mariage datant de plus de 75 ans sont ainsi accessibles en ligne librement depuis leur numérisation dans les années 2000 par les archives départementales qui ont mis en place des plateformes pour consulter à distance les actes d'état civil anciens¹.

Toutefois, en raison des limites techniques de l'époque, la numérisation de ces archives a été faite sous forme d'image. Si la consultation visuelle de l'image numérisée en ligne est possible, le traitement automatique de l'information qu'elle contient ne l'est pas, ce qui empêche toute étude quantitative de ces données basée sur un grand échantillon.

Objectifs du projet

Un premier objectif du projet serait **d'examiner la faisabilité d'extraction des données des actes de mariages numérisés à partir de techniques de reconnaissance optique des caractères**. Les actes de mariages sont rédigés sous forme manuscrite, sauf pour l'après-guerre où ils sont parfois dactylographiés. L'efficacité de la reconnaissance optique sur l'écriture manuscrite française du début du XXème siècle reste incertaine. Les actes sont généralement collectés sous forme de recueil. Ils peuvent être collectés sur plusieurs pages et plusieurs actes peuvent être répertoriés sur une même page.

Une fois le texte extrait, le second objectif du projet serait **d'extraire et d'organiser systématiquement les informations pertinentes contenue dans chaque acte dans une base de données**. Ainsi, pour chaque acte de mariage, l'information sur le lieu, la date, le nom, la profession, l'adresse des mariés ainsi que de leurs parents seraient collectés au sein d'une base de données manipulable.

Le troisième objectif, indispensable pour l'exploitation de ses données, serait **d'évaluer la qualité des données collectées**. Il serait également utile d'avoir une idée du taux d'erreur sur chaque variable collectée et de quelle manière ce taux d'erreur varie avec la méthode utilisée ou les caractéristiques des actes.

¹ Voir par exemple <https://francearchives.gouv.fr/fr/article/38170>

L'objectif final, qui dépasse le cadre du projet actuel, serait de collecter un échantillon représentatif des actes de mariages en ligne entre les différents départements.

Données utilisées :

Le jeu de données initial proviendrait de plusieurs années des actes de mariages numérisés des Archives de Paris². Les recueils sont organisés par années et arrondissement. Les années choisies et leur nombre restent à préciser mais les années 1913 et 1920 seront privilégiées afin de déterminer de quelle manière la Grande guerre a affecté le marché du mariage. Pour des raisons pratiques, nous prévoyons de demander les fichiers images aux archives avant leur traitement.

Livrables :

- Pipeline *comp/et* (script ou notebook) :
 - prétraitement, OCR, extraction, structuration.
 - Rapport **final** (10–15 pages):
 - description des méthodes,
 - comparaison des OCR,
 - protocole d'évaluation,
 - analyse des résultats,
 - exemples d'actes traités (images + texte OCR + structure finale).
 - Base **de données** (CSV ou SQL) contenant les champs extraits.

Notation :

Critères	Points
Prétraitement images et pipeline reproductible	4 pts
Mise en œuvre des OCR + comparaison de méthodes	4 pts
Extraction structurée (NER/regex/règles) + base de données	4 pts
Évaluation rigoureuse du taux d'erreur et analyse critique	4 pts
Qualité du rapport / rigueur scientifique / clarté	3 pts
Présentation orale ou démonstration	1 pt

Etude de cas 2 : Rain Prediction Challenge

Proposé par Souhila Arib, Enseignante -chercheur en IA au laboratoire ETIS

Email : souhila.arib@cyu.fr

Contexte et motivation

Les données météo sont riches et variées : pression, humidité, température, ensoleillement, vitesse du vent, etc. Prédire la probabilité qu'il pleuve le lendemain (ou à un moment donné) est un problème classique de machine learning avec des applications importantes (agriculture, énergie, transport, gestion des risques).

² Accessibles en lignes ici : <https://archives.paris.fr/>

Il existe sur Kaggle un dataset souvent appelé « Rain in Australia » (et des variantes de “Rain Prediction”) : les objectifs typiques comprennent la prédiction binaire (pluie ou non), mais aussi la modélisation probabiliste des précipitations.

Medium+3blog.csdn.net+3tracyrenee61.medium.com+3

- Par exemple, Kaouter Hassani décrit dans son projet comment elle a utilisé des données journalières (température, nuages, humidité, pression...) pour prédire un “RainTomorrow” binaire. Medium
- Le dataset “Rain in Australia” comprend près de 145 000 lignes et ~23 variables météo. Medium+2Peer-reviewed Journal+2
- L’évaluation se fait typiquement via une métrique ROC-AUC, ce qui encourage des modèles bien calibrés

Objectifs du projet

Les étudiants devront :

- 1. Explorer et nettoyer les données**
 - Analyse exploratoire (EDA) : distribution des variables, corrélations, valeurs manquantes.
 - Imputation ou traitement des valeurs manquantes.
 - Ingénierie de caractéristiques (feature engineering) : créer de nouvelles variables, dérivées, interactions, transformations.
- 2. Construire des modèles de prédiction**
 - Tester plusieurs approches : régression logistique, arbres de décision, forêts aléatoires, XGBoost, modèles plus avancés.
 - Envisager des modèles probabilistes (sortie comme probabilité de pluie).
 - Optionnel : modèles de deep learning si les étudiants le souhaitent (RNN, réseaux denses).
- 3. Valider les modèles rigoureusement**
 - Utiliser une stratégie de **validation croisée** stable.
 - Surveiller le sur-apprentissage, calibrer les probabilités si besoin.
 - Évaluer via ROC-AUC, mais aussi d’autres métriques (précision, rappel, courbes PR si classes déséquilibrées...).
- 4. Faire du tuning d’hyperparamètres**
 - Recherche d’hyperparamètres (GridSearch, RandomSearch, voire Optuna si possible).
 - Comparaison entre performance brute et performance calibrée.
- 5. Interpréter les modèles**
 - Importance des variables.
 - Analyse des erreurs ou des “faux positifs / négatifs” : à quel moment le modèle se trompe, et pourquoi.
 - Visualisations : heatmaps, partial dependence plots, etc.
- 6. (Optionnel, selon temps) Déployer ou présenter une application**
 - Créer un notebook interactif ou une petite application (Streamlit, Dash) pour montrer les prédictions.
 - Prévoir des scénarios “what-if” : si la température augmente, l’humidité change, comment la probabilité de pluie évolue ?
- 7. Rédiger un rapport**
 - Présenter méthodologie, résultats, comparaisons de modèles.
 - Discuter des limites, des biais potentiels des données, et des pistes d’amélioration.

Livrables : notebook (Jupyter / Colab), rapport PDF ou diaporama, éventuellement application web simple.

Notation :

Critères	Points
Exploration & preprocessing des données	4 pts
Ingénierie des caractéristiques	3 pts
Choix et implémentation des modèles	4 pts
Validation & tuning hyperparamétrique	3 pts
Évaluation rigoureuse / métriques	2 pts
Interprétabilité et analyse des résultats	2 pts
Application ou visualisation (optionnel)	1 pt
Rapport écrit / présentation	2 pts